1. Datos y análisis exploratorio

1.1. Calidad de los datos y valores faltantes

De las 20.424 horas del periodo, 1.033 (5,06 %) no tienen medición de PM2.5. Esa cifra agregada describe mal el problema: las ausencias se agrupan en 47 interrupciones con una mediana de 11 horas, y las 12 que duran 24 horas o más concentran 700 horas, el 68 % de todos los faltantes (la mayor dura 126 horas). El archivo no documenta la causa, por lo que no puede asumirse que los faltantes sean aleatorios. Si coincidieran con episodios de alta concentración, los estadísticos descriptivos subestimarían los valores extremos. Por eso no se imputa ni se interpola ningún valor: las horas sin medición se conservan explícitamente en la serie.

Se aplicaron tres controles de coherencia. Ninguna de las 18.671 horas con PM2.5 y PM10 simultáneos presenta PM2.5 por encima de PM10, la racha máxima de valores idénticos consecutivos es de 2 (descarta un sensor bloqueado) y se observaron 49 variaciones horarias superiores a 50 µg/m^3, con un máximo de 121,0. Estas últimas se señalan para revisión, pero no se descartan.

1.2. Distribución y valores extremos

La serie disponible (19.391 mediciones) tiene media de 29,29 y mediana de 24,50 µg/m^3, desviación estándar de 18,17, percentil 95 de 65,31 y máximo de 191,5. La asimetría es de 2,11: una minoría de horas con concentraciones altas arrastra el promedio. Al ser la variable objetivo continua, no existe un desbalance de clases en sentido estricto, pero la distribución produce un efecto equivalente, porque las concentraciones altas están poco representadas.

La regla de 1,5 veces el rango intercuartílico señala 1.126 mediciones (5,81 %). No se eliminan: el 95 % corresponde a 2022, se concentran entre mayo y octubre y entre las 12:00 y las 16:00, que es la franja de mayor mediana horaria. Un error instrumental no reproduciría esa estructura estacional y horaria, de modo que la evidencia favorece interpretarlas como episodios reales de contaminación, que además son las horas de mayor relevancia sanitaria. Como contexto, de los 795 días con al menos 18 horas medidas, el 93 % supera la guía diaria de la OMS (15 µg/m^3) y el 10,3 % el estándar peruano (50 µg/m^3).

1.3. Patrón diario y cambio de régimen

La mediana horaria alcanza su máximo a las 14:00 (34,4 µg/m^3) y su mínimo a las 22:00 (17,0), por lo que la hora del día está asociada al nivel de PM2.5. Esta es una diferencia descriptiva; que mejore la predicción debe comprobarse con modelos.

El nivel medio desciende a lo largo del periodo: 38,8 µg/m^3 en 2022, 23,8 en 2023 y 17,7 en enero–abril de 2024. Parte de la caída de 2024 es estacional, pero 2022 supera a 2023 en 11 de los 12 meses, con una diferencia concentrada entre mayo y octubre, de modo que el calendario no la explica por completo (Fig. 1). Una partición cronológica entrena entonces en un régimen de

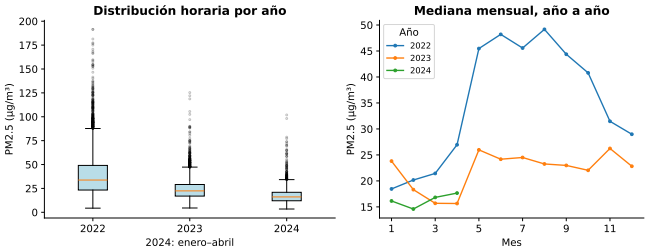


Figura 1: Cambio de nivel entre años y comparación de medianas mensuales.

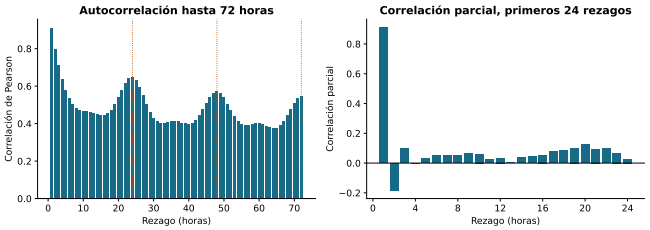


Figura 2: Autocorrelación y autocorrelación parcial de PM2.5 hasta 48 horas, calculadas con las horas en que ambos valores están disponibles.

concentraciones más altas que el de evaluación, y el error absoluto no es comparable entre tramos; las métricas deberán reportarse por separado para cada bloque.

1.4. Dependencia temporal

Entre horas consecutivas la correlación de Pearson es de 0,912 (19.343 pares completos). La autocorrelación cae a 0,464 en el rezago 12 y vuelve a subir a 0,651 en el rezago 24, lo que muestra el ciclo diario. La autocorrelación parcial se concentra en el primer rezago (0,912), es negativa en el segundo (−0,184) y no supera 0,12 en valor absoluto entre los rezagos 3 y 24 (Fig. 2). Los rezagos inmediatos aportan la información propia de corto plazo, mientras que el repunte a 24 horas corresponde al ciclo diario y puede representarse con variables de calendario en lugar de decenas de rezagos. Cuál de las dos opciones rinde más se responde comparando modelos con y sin calendario (pregunta de investigación 2).

1.5. Implicaciones para el modelado

El análisis exploratorio condiciona el diseño de la segunda etapa en cuatro puntos: los faltantes se agrupan en tramos y no se imputan, por lo que cada hora utilizable exige respuesta e historial completos; los valores extremos se conservan; la partición debe ser cronológica y sus métricas desagregadas por bloque, por el cambio de régimen; y el baseline natural es la persistencia, dada la correlación de 0,912 a una hora. Estas decisiones se concretan en la sección 2.

Cuadro 1: Variables del conjunto supervisado.

Variable	Definición
`pm25_t`	$\mathrm{PM}_{2,5}(t)$
`pm25_lag`k	$\mathrm{PM}_{2,5}(t-k)$, $k \in \{1,3,6,12,24\}$ h
`pm25_media`w`h`	media de las últimas $w \in \{3,6,24\}$ h, incluida t
`hora_objetivo`	hora del día de $t+1$ (0–23)
`dia_semana_objetivo`	día de la semana de $t+1$ (0 = lunes)
`y_pm25_t1`	respuesta: $\mathrm{PM}_{2,5}(t+1)$

2. Preprocesamiento e ingeniería de características

2.1. Conjunto supervisado y variable objetivo

Cada ejemplo corresponde a un instante t en que se hace el pronóstico. La respuesta es $y_t = \mathrm{PM}_{2,5}(t+1)$, la concentración exactamente una hora después, y las entradas usan únicamente mediciones en t o antes. Como la rejilla horaria se conserva completa, el desplazamiento corresponde siempre a una hora real y no al siguiente registro disponible. El valor actual $\mathrm{PM}_{2,5}(t)$ es además el pronóstico del baseline de persistencia, por lo que se incluye como entrada.

2.2. Variables de entrada

La Tabla 1 resume las 11 variables. Los rezagos de 1, 3 y 6 horas capturan la dependencia inmediata observada en la autocorrelación parcial; los de 12 y 24 horas recogen el ciclo diario; y las medias móviles de 3, 6 y 24 horas, que incluyen el instante t, resumen el nivel reciente con menor ruido que un valor aislado. Todas se calculan con desplazamientos hacia atrás o ventanas finales, de modo que ninguna contiene información posterior a t. Las medias móviles exigen la ventana completa; con un hueco, la fila se descarta.

La hora y el día corresponden a $t+1$, el instante que se pronostica, que se conoce de antemano. Se codifican dentro del pipeline: la hora con seno y coseno, para que las 23:00 y las 00:00 resulten vecinas, y el día de la semana con variables indicadoras, porque el efecto de fin de semana no sigue una senoide. El conjunto sin calendario usa solo las nueve variables de historial, con los mismos ejemplos, lo que permite comparar ambos enfoques en igualdad de condiciones.

2.3. Faltantes y ventanas incompletas

No se imputan valores, ni con ceros ni por interpolación. Un instante es utilizable solo si tiene la respuesta y todo su historial; en caso contrario se descarta. De los 20.424 instantes de la rejilla quedan 18.276 (89,5 %) (Tabla 2). Los descartes se deben a que 1.034 instantes no tienen respuesta, 1.033 no tienen medición actual, 1.967 tienen algún rezago faltante y 2.060 una media móvil incompleta (las causas se solapan). Como las interrupciones son largas, un solo hueco invalida muchas filas vecinas. Todos los modelos y el baseline se evalúan sobre estas mismas filas, para que las comparaciones no dependan de diferencias de muestra.

Cuadro 2: Filas descartadas por faltantes (las causas pueden coincidir).

Concepto	Filas	% rejilla
Instantes t en la rejilla	20.424	100,0
Sin respuesta $\mathrm{PM}_{2,5}(t+1)$	1.034	5,1
Sin medición actual	1.033	5,1
Algún rezago faltante	1.967	9,6
Alguna media móvil incompleta	2.060	10,1
Filas utilizables	**18.276**	**89,5**

Cuadro 3: Conjunto supervisado por bloque (respuesta en µg/m^3).

Bloque	Filas	Media	Mediana	P95	Máx.
Entrenamiento	11.551	32,9	27,8	72,2	191,5
Validación	4.024	25,1	23,7	41,8	125,3
Prueba	2.701	17,8	16,1	32,2	101,9

2.4. Partición cronológica

Los datos se dividen en tres bloques contiguos y disjuntos, sin barajar filas: entrenamiento (enero de 2022 a junio de 2023), validación (julio a diciembre de 2023) y prueba (enero a abril de 2024). La partición se asigna según el instante de la respuesta $t+1$, de modo que ninguna etiqueta de entrenamiento cae en el periodo de validación ni una de validación en el de prueba. Una fila de validación sí puede usar como entrada observaciones del periodo de entrenamiento, algo legítimo porque son pasadas. Los cortes se fijaron antes de ver resultados de ningún modelo. El ajuste de hiperparámetros se hará con validación de origen móvil dentro del entrenamiento, nunca con particiones aleatorias.

La Tabla 3 y la Fig. 3 muestran que la distribución de la respuesta cambia entre bloques: la media baja de 32,9 a 17,8 y el máximo de 191,5 a 101,9. El modelo se entrena, por tanto, en un régimen de concentraciones más altas del que se evalúa. Esto obliga a reportar las métricas por bloque y a comparar cada modelo con la persistencia calculada sobre el mismo bloque, ya que un mismo error absoluto no significa el mismo desempeño relativo en cada tramo.

2.5. Preprocesamiento dentro del pipeline y prevención de fuga

El escalado se ejecuta dentro de un `Pipeline` de scikit-learn: las nueve variables de historial se estandarizan con la media y la desviación del entrenamiento, y esos parámetros se aplican sin reajuste a validación y prueba. Ajustar el escalador con todos los datos filtraría información de los bloques posteriores: la media de $\mathrm{PM}_{2,5}(t)$ es de 32,94 en entrenamiento y de 28,98 en el conjunto completo.

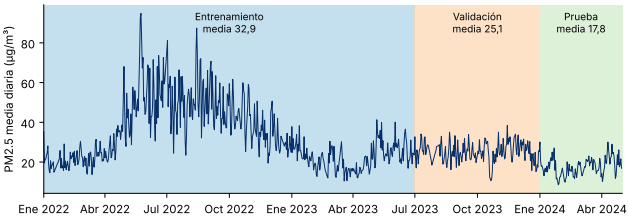


Figura 3: Partición cronológica sobre la media diaria de PM2.5 (días con al menos 18 horas medidas). Se indica la media de la respuesta de cada bloque.

Cuadro 4: Comprobaciones de ausencia de fuga de información.

Comprobación	Resultado
Recálculo independiente con solo el pasado (500 filas)	Superada
Las entradas no cambian si se altera el futuro (8 cortes)	Superada
Respuesta igual a $\mathrm{PM}_{2,5}(t+1)$ y calendario de $t+1$	Superada
Bloques ordenados, disjuntos y completos	Superada
Filas con hueco excluidas, sin ceros inventados	Superada
Escalador ajustado solo con entrenamiento (con y sin calendario)	Superada
Control negativo: una fuga deliberada es detectada	Superada

La ausencia de fuga se comprueba de forma explícita con un guion reproducible (`scripts/02_verificar_fuga.py`) que ejecuta 12 verificaciones, todas superadas (Tabla 4). La prueba central altera por completo los valores posteriores a un instante de corte y comprueba que las entradas en ese instante no cambian. Como control negativo, se añade a propósito una variable con información futura y se confirma que la prueba la detecta.